

1. 核心模型定义

在3分类逻辑回归中，不再像二分类那样使用单一的Sigmoid函数和单个权重向量，而是为每一个类别分配一组独立的权重矩阵和偏置。假设输入特征向量为 $x = [x_1, x_2, \dots, x_D]^T$ ，针对3个类别（Class 1, Class 2, Class 3），定义：

- 线性组合**：对于类别 $k \in \{1, 2, 3\}$ ，其线性输出为 $z_k = w^k \cdot x + b_k$ 。其中 w^k 是第 k 类的权重向量， b_k 是第 k 类的偏置。
- Softmax 激活函数**：将线性输出转化为概率分布。第 k 类的预测概率为：

$$y_k = P(C_k|x) = \frac{e^{z_k}}{\sum_{j=1}^3 e^{z_j}}$$

这保证了所有类别的预测概率大于0，且总和 $\sum_{j=1}^3 y_j = 1$ 。

- 真实标签**：如果样本属于类别 k ，则 $\hat{y}_k = 1$ ，其余类别的 $\hat{y}_i = 0$ ($i \neq k$)。
- 交叉熵损失函数**：对于单个样本，损失函数定义为真实分布与预测分布之间的交叉熵：

$$L = - \sum_{i=1}^3 \hat{y}_i \ln(y_i)$$

2. 链式法则推导梯度

为了使用梯度下降法更新第 k 类的权重 w^k 和偏置 b_k ，需要求解损失函数 L 对参数的偏导数。根据链式法则：

$$\frac{\partial L}{\partial w_j^k} = \frac{\partial L}{\partial z_k} \cdot \frac{\partial z_k}{\partial w_j^k}$$

$$\frac{\partial L}{\partial b_k} = \frac{\partial L}{\partial z_k} \cdot \frac{\partial z_k}{\partial b_k}$$

由于 $z_k = \sum_j w_j^k x_j + b_k$ ，显然有：

- $\frac{\partial z_k}{\partial w_j^k} = x_j$
- $\frac{\partial z_k}{\partial b_k} = 1$

因此，需要求解损失函数对线性输出的梯度： $\frac{\partial L}{\partial z_k}$ 。

3. 求解 $\frac{\partial L}{\partial z_k}$

第一步：Softmax 函数的导数 $\frac{\partial y_i}{\partial z_k}$

分两种情况讨论：

情况 A：当 $i = k$ 时（求自身类别的导数）

$$\frac{\partial y_k}{\partial z_k} = \frac{\partial}{\partial z_k} \left(\frac{e^{z_k}}{\sum_{j=1}^3 e^{z_j}} \right)$$

$$\frac{\partial y_k}{\partial z_k} = \frac{e^{z_k} \left(\sum_{j=1}^3 e^{z_j} \right) - e^{z_k} \cdot e^{z_k}}{\left(\sum_{j=1}^3 e^{z_j} \right)^2}$$

$$= \frac{e^{z_k}}{\sum_{j=1}^3 e^{z_j}} - \left(\frac{e^{z_k}}{\sum_{j=1}^3 e^{z_j}} \right)^2 = y_k - y_k^2 = y_k(1 - y_k)$$

情况 B：当 $i \neq k$ 时（求其他类别的导数）

$$\frac{\partial y_i}{\partial z_k} = \frac{\partial}{\partial z_k} \left(\frac{e^{z_i}}{\sum_{j=1}^3 e^{z_j}} \right)$$

此时分子 e^{z_i} 相对于 z_k 是常数，其导数为0：

$$\frac{\partial y_i}{\partial z_k} = \frac{0 \cdot \left(\sum_{j=1}^3 e^{z_j} \right) - e^{z_i} \cdot e^{z_k}}{\left(\sum_{j=1}^3 e^{z_j} \right)^2} = -\frac{e^{z_i}}{\sum_{j=1}^3 e^{z_j}} \cdot \frac{e^{z_k}}{\sum_{j=1}^3 e^{z_j}} = -y_i y_k$$

第二步：结合交叉熵损失求全导数

由于 $L = -\sum_{i=1}^3 \hat{y}_i \ln(y_i)$ ，应用全微分展开：

$$\frac{\partial L}{\partial z_k} = -\sum_{i=1}^3 \hat{y}_i \cdot \frac{1}{y_i} \cdot \frac{\partial y_i}{\partial z_k}$$

将总和拆分为 $i = k$ 和 $i \neq k$ 两部分，并代入第一步求得的导数：

$$\frac{\partial L}{\partial z_k} = -\left[\hat{y}_k \cdot \frac{1}{y_k} \cdot y_k(1 - y_k) + \sum_{i \neq k} \hat{y}_i \cdot \frac{1}{y_i} \cdot (-y_i y_k) \right]$$

化简表达式：

$$\frac{\partial L}{\partial z_k} = -\left[\hat{y}_k(1 - y_k) - \sum_{i \neq k} \hat{y}_i y_k \right]$$

$$\frac{\partial L}{\partial z_k} = -\left[\hat{y}_k - \hat{y}_k y_k - y_k \sum_{i \neq k} \hat{y}_i \right]$$

提取公因式 y_k ：

$$\frac{\partial L}{\partial z_k} = - \left[\hat{y}_k - y_k \left(\hat{y}_k + \sum_{i \neq k} \hat{y}_i \right) \right]$$

由于所有类别的真实概率之和必为1，即 $\sum_{i=1}^3 \hat{y}_i = 1$ 。因此，括号内的项 $(\hat{y}_k + \sum_{i \neq k} \hat{y}_i)$ 正好等于 1。

$$\frac{\partial L}{\partial z_k} = -[\hat{y}_k - y_k \cdot 1] = y_k - \hat{y}_k$$

这一简洁的结果展示出Softmax配合交叉熵完美抵消了指数函数的复杂导数，使得最终梯度 $(y_k - \hat{y}_k)$ 仅取决于预测误差的线性差值。误差越大，梯度越大，彻底避免了饱和区梯度消失的问题。

4. 最终参数梯度与权值迭代公式

将 $\frac{\partial L}{\partial z_k}$ 代回链式法则公式：

$$\frac{\partial L}{\partial w_j^k} = (y_k - \hat{y}_k) x_j$$

$$\frac{\partial L}{\partial b_k} = (y_k - \hat{y}_k)$$

在实际训练中，通常拥有一组包含 N 个样本的训练集数据 $(x^n, \hat{y}^n)$ 。全局损失函数是对所有样本损失的求和（或平均）。对于全体 N 个样本，第 k 个类别的第 j 个权重的总梯度为：

$$\frac{\partial L_{total}}{\partial w_j^k} = \sum_{n=1}^N (y_k^n - \hat{y}_k^n) x_j^n$$

采用学习率为 η 的梯度下降法（Gradient Descent），在每次迭代中，参数向着负梯度方向更新：

$$w_j^k \leftarrow w_j^k - \eta \sum_{n=1}^N (y_k^n - \hat{y}_k^n) x_j^n$$

写为向量形式，直接更新第 k 类的整个权重向量 w^k 和偏置 b_k ：

$$w^k \leftarrow w^k - \eta \sum_{n=1}^N (y_k^n - \hat{y}_k^n) x^n$$

$$b_k \leftarrow b_k - \eta \sum_{n=1}^N (y_k^n - \hat{y}_k^n)$$